

SOGANG PRESENTATION

이름 : 이재영

학번 : A71047

과목 : 강화학습의 기초

담당교수 : 소정민 교수님

* Github 주소

<https://github.com/leejaeyy/RL-Term-Project>




CONTENTS

- 01. 프로젝트 주제 및 목표
- 02. 데이터셋 및 State-Reward 설계
- 03. 강화학습알고리즘 및 hyperparameter 설명
- 04. 실험 셋업
- 05. 실험 결과
- 06. 토의 및 결론

01.

프로젝트 주제 및 목표

eCommerce 플랫폼의 할인 정책 최적화를 위한 강화학습
(DQN) 기반 의사결정 모델 개발을 목표




1. 프로젝트 주제 및 목표

- 1) eCommerce 실제 구매 로그를 기반으로 강화학습 환경(MDP) 을 구성한다.
(State, Action, Reward를 정의하여 고객-정책 상호작용을 시뮬레이션)
- 2) DQN 알고리즘을 적용하여,
각 고객 상태에 맞는 최적의 할인 정책(쿠폰 제공 수준)을 학습하도록 한다.
- 3) 학습 로그(train_log.csv)와 시각화(Return, Epsilon Decay, Action Distribution)를 통해
정책의 수렴 과정 및 탐험-활용 균형 변화를 분석한다.
- 4) 단순 무작위 정책 대비 DQN 정책의 보상(수익률) 향상 효과를 검증한다

02.

데이터셋 및 State-Reward 설계

- 데이터 셋
- 데이터 개요 및 전처리 (preprocessing.py)
- State, action, reward 설계



데이터 셋

- RAW DATA : kz.csv

kz.csv는 2020년 4월부터 2020년 11월까지 대형 가전제품 및 전자제품 온라인 매장에서 구매한 데이터

데이터 출처 (Data Source)

KZ.csv 데이터는 Kaggle의 공개 e-Commerce 데이터

Kaggle Dataset 링크:

<https://www.kaggle.com/datasets/mkechinov/ecommerce-purchase-history-from-electronics-store>

데이터 개요 및 전처리

eCommerce 플랫폼의 거래 로그 데이터(kz.csv) 를 기반으로 강화학습 학습용 상태 데이터셋 **states_30d.csv** 를 생성

- **원본 데이터(kz.csv)**

고객 ID(user_id), 거래 시점(event_time), 구매 금액(price), 상품 카테고리(category) 등으로 구성된 원시 거래 로그

- **전처리 과정 (preprocessing.py)**

- 1) 고객 단위로 30일 간의 거래 이력을 집계
- 2) 각 고객의 구매 패턴을 아래 네 가지 특징(State)으로 변환
- 3) 모든 특징값을 **0~1 범위로 정규화(Min-Max Scaling)** 수행

생성된 states_30d.csv는 이후 **MDP 기반 환경(env.py)** 의 입력으로 사용

State - Action 설계

State (상태)

고객의 최근 구매 패턴을 나타내는 4가지 지표로 구성.

- recency_norm: 마지막 구매 이후 경과일
 - frequency_norm: 일정 기간 내 구매 횟수
 - avg_price_norm: 평균 구매 금액
 - diversity_norm: 구매 카테고리 다양도
- 모든 변수는 0~1 범위로 정규화되어 모델 입력으로 사용됨.

Action (행동)

에이전트는 각 시점에서 다음 중 하나의 할인 정책을 선택.

1. 무행동 (할인 없음)
2. 5% 할인 쿠폰 제공
3. 10% 할인 쿠폰 제공
4. 20% 할인 쿠폰 제공

→ 행동은 고객의 구매 확률과 기업의 이익률 모두에 영향을 미친다.

Reward 설계

eCommerce 환경에서의 보상은 **고객의 구매 행동과 할인 비용을 함께 반영하도록 설계**

기본적으로 고객이 구매하지 않은 경우에는 작은 패널티를,
구매가 발생한 경우에는 구매 금액을 기준으로 한 정규화된 보상을 부여

- 미구매 시 : -0.1 (학습 안정화를 위한 경미한 패널티)
- 구매 시
 - 기본 보상 = (구매 금액 $\div$ 전체 중간값)
 - 할인 비용 = {5%, 10%, 20%}에 해당하는 쿠폰 제공 비용
 - 최종 보상 = 기본 보상 $\times$ (1 - 할인율)

에이전트는 **높은 매출을 유도하면서도 과도한 할인 비용을 최소화하는 방향으로 학습**
단순한 구매 유도가 아닌 수익성 기반의 행동 정책(Profit-oriented Policy)을 학습하도록 설계된 것.

03.

강화학습 알고리즘 및 hyperparameter 설명

- DQN 알고리즘
- Hyperparameter 설명



강화학습 알고리즘 및 hyperparameter 설명

DQN 알고리즘을 활용하여 고객 행동 정책을 학습하는 강화학습 모델을 구현

Replay Buffer로 경험 샘플을 저장하고 미니배치 학습 수행

Target Network를 통해 학습 안정화

ϵ -Greedy Policy로 탐험(Exploration)과 활용(Exploitation)의 균형 유지

- 핵심 하이퍼파라미터 설정

γ (Gamma) = 0.90 → 미래 보상에 대한 할인율

lr (Learning Rate) = 1e-3 → Adam Optimizer 학습률

τ (Tau) = 0.005 → Target Network Soft Update 비율

ϵ (탐험률) = 1.0 → 0.05 (8,000 step 동안 선형 감소)

DQN 기반의 강화학습 구조를 적용하여 "고객별 최적 할인정책"을 학습하고, 탐험률 조정과 안정적 Q-value 업데이트로 정책 수렴을 유도


04.

실험 셋업

- 실험환경
- Evaluation metric(평가 지표)



서강대학교
SOGANG UNIVERSITY



실험 셋업 (Experimental Setup)

Python, PyTorch기반으로 구성되었으며, 전처리된 고객 상태 데이터(states_30d.csv)를 사용

1) 실험 환경

- 데이터: 고객 30일 거래 로그 기반 상태 데이터셋(states_30d.csv)

2) 평가 지표 (Evaluation Metric)

모델의 학습 진행과 정책 효율성을 평가하기 위해 세 가지 주요 지표를 사용

- **Episode Return**

→ 에피소드별 누적 보상값으로, 정책이 얼마나 높은 수익을 학습했는지를 나타냄.

- **Epsilon Decay Curve**

→ 탐험(Exploration)과 활용(Exploitation)의 전환 과정을 추적하며, 학습 안정성을 평가.


- **Action Distribution**

→ 각 할인율 정책(Action)이 선택된 빈도를 시각화하여, 정책의 행동 경향을 분석.


05.

실험 결과

- Hyperparameter Variation 결과 비교
- Seed 변화 실험 및 신뢰도 분석
- 실험 결과 종합



Hyperparameter Variation 결과 비교 2



✓ 사용한 파라미터

episodes = 5000

epsilon_decay_steps = 3000

✓ 결과

- Return 스파이크 많음
- ϵ 가 거의 0.7 이상 유지됨 → 지나치게 탐험 지속
- Action distribution이 균등에 가까워짐

✓ 해석

- 높은 reward 패턴을 많이 발견하지만, 정책이 안정적으로 수렴하지 못함.
- 실전에서는 탐험이 너무 많으면 손실이 커지는 문제

→ 학습은 되지만 안정적이지 않은 결과

Hyperparameter Variation 결과 비교 1



✓ 사용한 파라미터

episodes = 200

epsilon_decay_steps = 30,000


✓ 결과

- Return 대부분 0~20
- ϵ 거의 감소하지 않아 random policy 유지
- Action 분포가 **700:700:700:700** (완전 균등)

✓ 해석

- 학습이 충분히 진행되지 않아 정책이 전혀 형성되지 않음.

Hyperparameter Variation 결과 비교 3



✓ 사용한 파라미터

episodes = 5000

epsilon_decay_steps = 1000

✓ 결과


- 빠르게 수렴하여 return 변동성 낮아짐
- 스파이크는 있으나 다양성 적음 (탐험 시간 부족)
- Action distribution[act0 : 약 20,000, act3 낮음]

✓ 의미

탐험은 부족하지만 빠르고 안정적인 정책이 형성됨.
다만 충분한 high-reward 패턴을 놓칠 가능성 존재.

→ 수렴 속도는 빠르나 성능 최적은 아님

Hyperparameter Variation 결과 비교 4



✓ 사용한 파라미터

episodes = 5000

epsilon_decay_steps = 3000

✓ 결과

안정적 수렴 + 적절한 스파이크 발생

ϵ decay가 가장 합리적 → 충분한 탐험 + 적절한 exploitation

Action distribution: [act0 $\approx$ 10,000, act1 $\approx$ 8,000, act2 $\approx$ 6,500, act3 $\approx$ 3,500]

→ 할인 비용을 학습하여 "필요할 때만 최소 할인 전략"으로 수렴하는 가장 자연스러운 전략

✓ 의미

탐험과 활용의 균형이 가장 잘 맞아 최적의 정책을 안정적이면서 reward를 극대화하는 policy로 수렴.

Seed 변경 실험 개요

1. 실험 목적

DQN 모델의 안정성(robustness)과 재현성(reproducibility)을 검증하기 위해 다양한 난수 초기값(seed)에서 학습을 반복 실행하였다.

2. Seed 설정

사용한 Seed 값: **0, 1, 42, 100, 123** (총 5회 학습 실행)
동일한 환경, 동일한 하이퍼파라미터에서 **난수 상태만 변화**

3. 분석 항목

Episode Return의 **평균(Mean)**
Episode 간 성능 분포의 **95% 신뢰구간(Confidence Interval)**
Seed별 Episode Return 곡선 비교

4. 기대 효과

Seed 변화에도 유사한 성능을 보이면
→ **모델이 안정적으로 수렴하는지** 확인 가능
결과 간 편차가 크지 않으면
→ **DQN이 일관된 정책을 학습**한다는 근거 확보


Seed 변경 실험 결과

로드된 파일: ['train_log_seed0.csv', 'train_log_seed1.csv', 'train_log_seed100.csv', 'train_log_seed123.csv', 'train_log_seed42.csv']

최소 episode 길이: 600

최종 데이터 shape: (5, 600)

저장 완료: seed_CI_safe.png



1) Seed 변화에도 학습 패턴 거의 동일

전체 Episode Return 곡선의 진동 범위와 패턴이 Seed 간 유사
Exploration 경로 차이에 따른 초기 편차만 매우 작게 발생

2) 평균 Return의 정형화된 패턴 확인

대부분 Episode Return이 낮은 값에서 안정
특정 상황에서만 고보상 스파이크 발생 → 환경의 특성에 기인
Seed가 달라도 스파이크의 위치·빈도가 매우 유사하게 나타남

3) 매우 좁은 95% 신뢰구간

5회 반복 학습의 분포 폭이 작음

→ 모델의 재현성 높음

→ DQN 학습이 초기 Randomness의 영향을 거의 받지 않음


- 결론

Episode Return 평균 및 신뢰구간이 거의 동일하게 수렴.
이는 DQN 모델이 Random 초기값의 영향을 크게 받지 않으며,
높은 안정성과 재현성을 가진다는 점을 명확하게 보여준다.

06.

토의 및 결론

- DQN 학습 성과
 - > 할인 정책 최적화 모델 구축
- 한계 및 개선점, 결론



DQN 학습 성과 및 한계, 개선점

DQN 학습 성과

1. 학습이 진행될수록 Episode Return 점진적 상승 및 안정화
2. Epsilon Decay를 통해 탐험(Exploration)에서 활용(Exploitation)으로 자연스럽게 전환
3. 행동 선택(Action Distribution) 결과, 무할인 및 저할인 정책 중심으로 수렴
4. DQN이 비용 효율성과 구매 확률 간의 균형 전략을 성공적으로 학습

한계 및 개선점

실제 구매 확률은 가격 외에도 시간대, 카테고리, 고객 특성 등 다양한 요인에 영향을 받음

보상 설계를 단일 수익 중심 → 복합 보상(재구매율, 이탈률 등) 으로 확장 필요

DQN 외에도 **Double DQN, Dueling DQN, PPO** 등의 알고리즘 비교를 통한 성능 검증

결론

- DQN은 단순한 구조에서도 안정적 정책 학습과 수렴성 확보
- 강화학습 기반 할인 정책이 데이터 기반 마케팅 자동화의 유효한 방법임을 확인
- 향후 고도화된 모델을 적용해 실제 프로모션 정책 최적화 시스템으로 확장 가능